Introducción al Machine Learning

Segundo Examen Parcial

Universidad El Bosque

Programa de Matemáticas y Estadística

Semestre 2026–2

Parte I. Experimento computacional

La entrega consiste en un **proyecto modular desarrollado en parejas y entregado mediante un repositorio de GitHub**. Se proporcionan los archivos

`train_A.csv`, `train_B.csv`, `train_C.csv`, `validation.csv`,

todos con las columnas `x` y `y`. Los tres conjuntos de entrenamiento son muestras diferentes obtenidas bajo las mismas condiciones. El conjunto `validation.csv` no debe utilizarse para ajustar los modelos.

En todos los ejercicios use la pérdida cuadrática y el riesgo empírico

$$\hat{R}_S(h) = \frac{1}{n}\sum_{i=1}^{n}\big(y_i - h(x_i)\big)^2.$$

Puede utilizar `PolynomialFeatures` y `LinearRegression` de `scikit-learn`. El cálculo del riesgo debe implementarse como una función propia.

Ejercicio 1. Complejidad y generalización [1.5]

Utilice únicamente `train_A.csv` para ajustar regresiones polinomiales de grados

$$d = 1, 2, \ldots, 15.$$

Implementación modular. Use `data.py` para cargar los datos, `models.py` para ajustar y predecir, `risk.py` para el riesgo cuadrático y `analysis.py` para recorrer los grados y reunir los resultados. El cuaderno debe importar estas funciones y presentar sus salidas.

(a) Para cada grado calcule el riesgo sobre `train_A.csv` y sobre `validation.csv`. Presente una tabla con las columnas grado, riesgo de entrenamiento y riesgo de validación.

(b) Grafique, en una misma figura, el riesgo de entrenamiento y el riesgo de validación en función del grado.

(c) Determine

$$d_{\text{train}} = \arg\min_d \hat{R}_{\text{train}}(d), \qquad d_{\text{val}} = \arg\min_d \hat{R}_{\text{val}}(d).$$

Reporte ambos grados y sus respectivos riesgos.

(d) Considere únicamente los grados $2, 6, 15$. Asocie, usando cada categoría exactamente una vez,

$$\textit{subajuste}, \qquad \textit{mejor balance}, \qquad \textit{sobreajuste},$$

con los tres grados. Para cada asociación reporte los riesgos de entrenamiento y validación que sustentan su elección.

Ejercicio 2. Sensibilidad a la muestra [1.5]

Considere ahora los tres conjuntos `train_A.csv`, `train_B.csv` y `train_C.csv`, pero únicamente los grados

$$d \in \{2, 6, 15\}.$$

Para cada grado ajuste un modelo con cada conjunto de entrenamiento. Denote estos modelos por

$$\hat{h}_{A,d}, \qquad \hat{h}_{B,d}, \qquad \hat{h}_{C,d}.$$

Implementación modular. Reutilice `data.py`, `models.py` y `risk.py`. En `analysis.py` implemente la evaluación sobre la malla común y los cálculos de $\bar{h}_d$ y V_d; el cuaderno debe usarlos para producir las figuras y resultados.

(a) Para cada grado construya una gráfica que muestre simultáneamente las tres hipótesis aprendidas. Deben obtenerse tres figuras en total.

(b) Construya una malla de $m = 300$ puntos igualmente espaciados en $[-2{,}5, 2{,}5]$. Para cada $d \in \{2, 6, 15\}$, defina

$$\bar{h}_d(x_j) = \frac{1}{3}\left(\hat{h}_{A,d}(x_j) + \hat{h}_{B,d}(x_j) + \hat{h}_{C,d}(x_j)\right)$$

y calcule

$$V_d = \frac{1}{m}\sum_{j=1}^{m}\left[\frac{1}{3}\sum_{S\in\{A,B,C\}}\left(\hat{h}_{S,d}(x_j) - \bar{h}_d(x_j)\right)^2\right].$$

Reporte V_2, V_6, V_{15}.

(c) Ordene $2, 6, 15$ de menor a mayor valor de V_d. Identifique cuál de los tres modelos es el más sensible al cambio de muestra y cuál es el más estable.

(d) Asocie, utilizando cada opción una sola vez,

$$\textit{alto sesgo}, \qquad \textit{balance sesgo–varianza}, \qquad \textit{alta varianza},$$

con los grados $2, 6, 15$. Para cada asociación reporte V_d y el riesgo promedio de validación de ese grado.

Ejercicio 3. Selección del modelo [1.0]

Para cada $d \in \{2, 6, 15\}$, defina el riesgo promedio de validación

$$\overline{R}_{\text{val}}(d) = \frac{1}{3}\sum_{S\in\{A,B,C\}}\hat{R}_{\text{validation}}(\hat{h}_{S,d}).$$

Implementación modular. En `analysis.py` calcule $\overline{R}_{\text{val}}(d)$ a partir de los resultados anteriores. No vuelva a implementar en el cuaderno la carga, el ajuste, el riesgo ni V_d.

(a) Complete la siguiente tabla.

Grado	$\overline{R}_{\text{val}}(d)$	V_d
2		
6		
15		

(b) Se desea utilizar un único grado para entrenar futuros modelos sobre nuevas muestras obtenidas bajo las mismas condiciones. Seleccione, entre $2, 6, 15$, el grado que presente el mejor comportamiento conjunto en validación y sensibilidad a la muestra. Debe escoger **un solo grado** y señalar los dos valores de la tabla anterior que sustentan la selección.

(c) ¿El grado seleccionado en el literal anterior coincide con el grado que produce el menor riesgo de entrenamiento en `train_A.csv`? Responda **sí** o **no** y reporte ambos grados.

(d) Un estudiante afirma: "el grado de mayor complejidad debe preferirse porque alcanza el menor riesgo de entrenamiento". Determine si esta afirmación es compatible con los resultados del experimento. Responda **sí** o **no** y reporte un par de valores numéricos que decida la respuesta.

Entrega

La entrega consiste en un **repositorio de GitHub que contenga un proyecto modular y reproducible**. Se espera una organización similar a la utilizada en las entregas anteriores. Como mínimo, el repositorio debe tener la siguiente estructura:

```
segundo_parcial/
|-- README.md
|-- requirements.txt
|-- pyproject.toml
|-- data/
|   |-- train_A.csv
|   |-- train_B.csv
|   |-- train_C.csv
|   `-- validation.csv
|-- src/
|   `-- parcial_ml/
|       |-- __init__.py
|       |-- data.py
|       |-- models.py
|       |-- risk.py
|       `-- analysis.py
|-- notebooks/
|   `-- parcial.ipynb
`-- resultados/
```

No se considerará modular una solución en la que el mismo bloque de código aparezca repetido cambiando únicamente el grado, el archivo o el conjunto de datos. El cuaderno debe ejecutarse completo desde un kernel reiniciado y el `README.md` debe explicar cómo instalar el proyecto y reproducir los resultados. Se espera un historial de Git coherente. La entrega final corresponde al enlace del repositorio de GitHub.